

# Statistique & Apprentissage

Paul-Henry Cournède

*paul-henry.cournede@centralesupelec.fr*

2018-2019

# Organisation du cours

## 2 Parties

- Partie I : **Éléments de Statistique Mathématique**
  - 5 Amphis, 5 TDs, dont 2 amphis pour commencer, 2 TDs pour finir.
  - 1 **Contrôle sans document** le 20/05 : exercices mathématiques
- Partie II : **Apprentissage statistique**  
(= Statistical Learning  $\approx$  Machine Learning)
  - 4 Amphis, 4 TDs
  - 1 **Contrôle sans document** le 07/06 : QCM
  - 4 séances de TPs sous Python

## Supports

- Notes de cours et Enoncés de TDs
  - disponibles cette semaine à la reprographie pour la partie I
  - disponibles un peu plus tard pour la partie II
- Corrigés des exercices disponibles sur EDUNAO après chaque TD

## TDs

- Avancés + Normaux

## Mille excuses par avance...

- (Généralement) pas de réponse aux questions par mail.

# Définition

“ **Statistique** : Branche des mathématiques ayant pour objet l'analyse et l'interprétation de données quantifiables.”

*Dictionnaire TLF*



# Définition

“ **Statistique** : Branche des **mathématiques** ayant pour objet l'analyse et l'interprétation de **données** quantifiables.”

*Dictionnaire TLF*

# Data everywhere !


## Médecine




## Finance



## Réseaux sociaux





## Environnement, Agriculture



# Data everywhere !


## Médecine




## Finance



## Réseaux sociaux



## Environnement, Agriculture



Disponibilité des données, algorithmes et méthodes statistiques de traitement des données, moyens de calcul  $\Rightarrow$  Révolution de l'**Intelligence Artificielle**

# Objectifs du Cours de Statistique

## Définition

Une donnée est la réalisation d'une variable aléatoire.

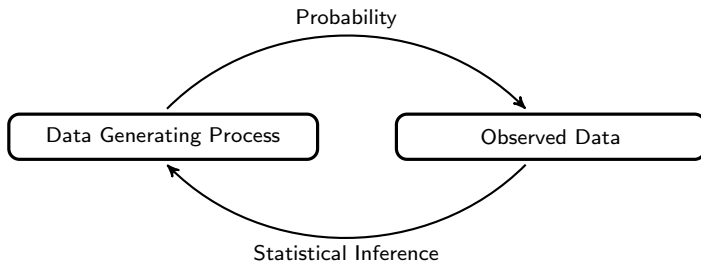
# Objectifs du Cours de Statistique

## Définition

Une donnée est la réalisation d'une variable aléatoire.

La variable aléatoire représente un phénomène inconnu que l'on souhaite étudier.

Pour cela la Statistique se place **dans l'espace des observations**, et à partir de données, nous réalisons une **inférence sur la loi de probabilité inconnue** de la variable aléatoire sous-jacente.





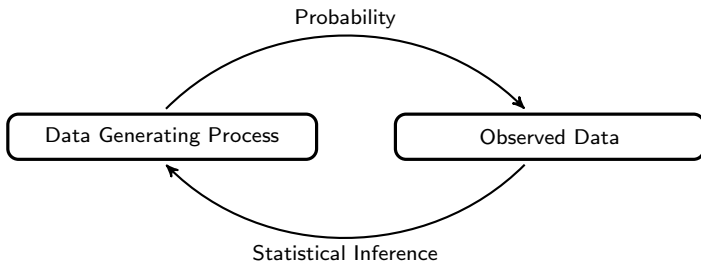
# Objectifs du Cours de Statistique

## Définition

Une donnée est la réalisation d'une variable aléatoire.

La variable aléatoire représente un phénomène inconnu que l'on souhaite étudier.

Pour cela la Statistique se place **dans l'espace des observations**, et à partir de données, nous réalisons une **inférence sur la loi de probabilité inconnue** de la variable aléatoire sous-jacente.



Avec deux objectifs :

- analyser un phénomène passé (**statistique descriptive**)
- prédire un phénomène futur à partir de l'analyse du passé (**statistique prédictive ou inférentielle**)

## Ce que nous allons voir ...

### ① Modèles statistiques paramétriques

$$X \sim P_{\theta}, \theta \in \Theta$$

## Ce que nous allons voir ...

### ① Modèles statistiques paramétriques

$$X \sim P_{\theta}, \theta \in \Theta$$

### ② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

## Ce que nous allons voir ...

### ① Modèles statistiques paramétriques

$$X \sim P_{\theta}, \theta \in \Theta$$

### ② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

### ③ Caractérisation de l'incertitude d'estimation par des intervalles de confiance

On cherche  $\theta_1, \theta_2$  tels que  $\theta \in [\theta_1, \theta_2]$  à 95%

## Ce que nous allons voir ...

① Modèles statistiques paramétriques  $X \sim P_\theta, \theta \in \Theta$

② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

③ Caractérisation de l'incertitude d'estimation par des intervalles de confiance

On cherche  $\theta_1, \theta_2$  tels que  $\theta \in [\theta_1, \theta_2]$  à 95%

④ Tests d'Hypothèses pour la validation des modèles

$H_0 : \theta = \theta_0$  versus  $H_1 : \theta \neq \theta_0 \implies$  Test paramétrique

ou

$H_0 : X \sim P_\theta$  versus  $H_1 : X \sim Q_\lambda \implies$  Test d'ajustement

## Ce que nous allons voir ...

① Modèles statistiques paramétriques  $X \sim P_\theta, \theta \in \Theta$

② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

③ Caractérisation de l'incertitude d'estimation par des intervalles de confiance

On cherche  $\theta_1, \theta_2$  tels que  $\theta \in [\theta_1, \theta_2]$  à 95%

④ Tests d'Hypothèses pour la validation des modèles

$H_0 : \theta = \theta_0$  versus  $H_1 : \theta \neq \theta_0 \implies$  Test paramétrique

ou

$H_0 : X \sim P_\theta$  versus  $H_1 : X \sim Q_\lambda \implies$  Test d'ajustement

⑤ Cas des modèles conditionnels : l'apprentissage supervisé

$Y \sim P_\theta(Y|X)$ , ou  $Y$  est la variable à expliquer,  $X$  les variables explicatives.

$Y \in \mathbb{R} \implies$  Régression ;  $Y \in \{0; 1; \dots; K\} \implies$  Classification

## Ce que nous allons voir ...

① Modèles statistiques paramétriques  $X \sim P_\theta, \theta \in \Theta$

② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

③ Caractérisation de l'incertitude d'estimation par des intervalles de confiance

On cherche  $\theta_1, \theta_2$  tels que  $\theta \in [\theta_1, \theta_2]$  à 95%

④ Tests d'Hypothèses pour la validation des modèles

$H_0 : \theta = \theta_0$  versus  $H_1 : \theta \neq \theta_0 \implies$  Test paramétrique

ou

$H_0 : X \sim P_\theta$  versus  $H_1 : X \sim Q_\lambda \implies$  Test d'ajustement

⑤ Cas des modèles conditionnels : l'apprentissage supervisé

$Y \sim P_\theta(Y|X)$ , ou  $Y$  est la variable à expliquer,  $X$  les variables explicatives.

$Y \in \mathbb{R} \implies$  Régression ;  $Y \in \{0; 1; \dots; K\} \implies$  Classification

⑥ Réduction de dimension pour les données de grande dimension

$x \in \mathbb{R}^p$ , on cherche  $y \in \mathbb{R}^m$ ,  $m \ll p$ , et  $\psi$  tels que  $\|x - \psi(y)\| < \epsilon$

## Ce que nous allons voir ...

① Modèles statistiques paramétriques  $X \sim P_\theta, \theta \in \Theta$

② Estimation Paramétrique

soient  $x_1, x_2, \dots, x_N$ , observations de  $X$ , on cherche  $\hat{\theta}$  qui approche  $\theta$

③ Caractérisation de l'incertitude d'estimation par des intervalles de confiance

On cherche  $\theta_1, \theta_2$  tels que  $\theta \in [\theta_1, \theta_2]$  à 95%

④ Tests d'Hypothèses pour la validation des modèles

$H_0 : \theta = \theta_0$  versus  $H_1 : \theta \neq \theta_0 \implies$  Test paramétrique

ou

$H_0 : X \sim P_\theta$  versus  $H_1 : X \sim Q_\lambda \implies$  Test d'ajustement

⑤ Cas des modèles conditionnels : l'apprentissage supervisé


$Y \sim P_\theta(Y|X)$ , ou  $Y$  est la variable à expliquer,  $X$  les variables explicatives.

$Y \in \mathbb{R} \implies$  Régression ;  $Y \in \{0; 1; \dots; K\} \implies$  Classification

⑥ Réduction de dimension pour les données de grande dimension

$x \in \mathbb{R}^p$ , on cherche  $y \in \mathbb{R}^m$ ,  $m \ll p$ , et  $\psi$  tels que  $\|x - \psi(y)\| < \epsilon$

⑦ Identification de sous-populations de variables aléatoires : Clustering





## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

## I - Modélisation Statistique


### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



## I - Modélisation Statistique


### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



# I - Modélisation Statistique


## I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



# I - Modélisation Statistique


## I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



# I - Modélisation Statistique


## I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



## I - Modélisation Statistique


### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.



## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.


#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .





## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.


#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .



## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.


#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .



## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.


#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .



## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad & \mathcal{A} \rightarrow [0; 1] \\ & A \mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application mesurable :

$$\begin{aligned} P_X : \quad & \mathcal{A} \rightarrow [0; 1] \\ & A \mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une densité par rapport à  $\mu$  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application :

$$P_X : \begin{aligned} \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une densité par rapport à  $\mu$  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une densité par rapport à  $\mu$  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une densité par rapport à  $\mu$  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$



## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application :

$$\begin{aligned} P_X : \quad \mathcal{A} &\rightarrow [0; 1] \\ A &\mapsto \mathbb{P}(X^{-1}(A)) \end{aligned}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une densité par rapport à  $\mu$  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

## I - Modélisation Statistique

### I.1 - Cadre Probabiliste

Soit  $(\Omega, \mathcal{F}, \mathbb{P})$  un espace probabilisé, soit  $(\mathcal{X}, \mathcal{A})$  un espace mesurable.

#### Définition

Une **variable aléatoire** (v.a.)  $X$  est une application mesurable de  $\Omega$  dans  $\mathcal{X}$ .

Soit  $\omega \in \Omega$ . La valeur  $X(\omega)$  est une **réalisation** de la v.a. aussi appelée **observation** ou **donnée**.

#### Définition

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ . L'application :

$$P_X : \begin{array}{l} \mathcal{A} \rightarrow [0; 1] \\ A \mapsto \mathbb{P}(X^{-1}(A)) \end{array}$$

est une mesure de probabilité sur  $\mathcal{A}$ , appelée **loi de probabilité de la variable aléatoire**  $X$ .

On note :  $X \sim P_X$ .

#### Définition

Une mesure  $\sigma$ -finie  $P$  est dite **dominée** par une mesure  $\sigma$ -finie  $\mu$  si tous les ensembles négligeables pour  $P$  le sont aussi pour  $\mu$ .

#### Théorème

Soit  $P$  mesure de probabilité.  $P$  admet une **densité par rapport à  $\mu$**  ssi  $P$  est dominée par  $\mu$ . La densité est alors la dérivée de Radon-Nikodym  $\frac{dP}{d\mu}$ .

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **comptage**.

$$A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) = \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) = \sum_{\alpha \in A} P_X(\alpha)$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

#### Définition : Échantillon aléatoire

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ . On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$E : \begin{array}{l} (\Omega^N, \mathcal{F}^{\otimes N}) \rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) \rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{array}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué** (i.i.d.).

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit **échantillon d'observations**.

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\implies$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\implies$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.

Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .

Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\implies$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.

Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .

Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\implies$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit :  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.

Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .

Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\implies$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\implies$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.

Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .

Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire **i.i.d.** de loi  $P_X$ .

La **mesure empirique** est une statistique de l'échantillon à valeurs dans l'espace des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$  définie par :

$$\hat{P}(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N \delta_{X_i}$$

où  $\delta_{X_i}$  est la mesure de Dirac en  $X_i$  :  $\forall A \in \mathcal{A}$ ,

$$\delta_{X_i}(A) = \begin{cases} 1 & \text{si } X_i \in A \\ 0 & \text{sinon} \end{cases}$$

Dans ce cours,  $\mathcal{X} \subset \mathbb{R}^d$  :

Variables aléatoires **continues**  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **Lebesgue**.

$$A \in \mathcal{A} \subset \mathcal{B}(\mathbb{R}^d) : P_X(A) = \int_A p(x) \lambda_d(dx)$$

Variables aléatoires **discrètes** à valeurs dans  $\Rightarrow$  mesure de référence  $\mu =$  mesure de **comptage**.

$$\begin{aligned} A \in \mathcal{A} = \mathcal{P}(\mathcal{X}) : P_X(A) &= \int_A p(x) K(dx) = \sum_{\alpha \in A} \mathbb{P}(X = \alpha) \\ &= \sum_{\alpha \in A} P_X(\alpha) \end{aligned}$$

Toutes les lois des v.a. considérées admettront une densité par rapport à l'une ou l'autre de ces mesures de référence.

### Définition : Échantillon aléatoire

Soit  $X$  v.a. de  $(\Omega, \mathcal{F}, \mathbb{P})$  dans  $(\mathcal{X}, \mathcal{A})$ , de loi  $P_X$ .

On appelle **échantillon aléatoire** de taille  $N$  la v.a. :

$$\begin{aligned} E : (\Omega^N, \mathcal{F}^{\otimes N}) &\rightarrow (\mathcal{X}^N, \mathcal{A}^{\otimes N}) \\ (\omega_1, \dots, \omega_N) &\rightarrow (X(\omega_1), \dots, X(\omega_N)) \end{aligned}$$

Si  $E$  est de loi  $\mathbb{P}_X^{\otimes N}$ , il est alors équivalent de considérer  $X_1, \dots, X_N$ ,  **$N$  variables aléatoires indépendantes de même loi  $P_X$** .

Le vecteur aléatoire  $(X_1, \dots, X_N)$  est alors dit **échantillon aléatoire indépendant identiquement distribué (i.i.d.)**.

Le vecteur d'observations associées  $(x_1, \dots, x_N)$  est dit échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.

Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .

Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire **i.i.d.** de loi  $P_X$ .

La **mesure empirique** est une statistique de l'échantillon à valeurs dans l'espace des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$  définie par :

$$\hat{P}(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N \delta_{X_i}$$

où  $\delta_{X_i}$  est la mesure de Dirac en  $X_i : \forall A \in \mathcal{A}$ ,

$$\delta_{X_i}(A) = \begin{cases} 1 & \text{si } X_i \in A \\ 0 & \text{sinon} \end{cases} \quad \text{Soit } (x_1, \dots, x_N) \text{ un}$$

échantillon d'observations,  $\hat{P}(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$  sera la mesure empirique associée à l'échantillon d'observations.



## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.  
Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .  
Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire **i.i.d.** de loi  $P_X$ .  
La **mesure empirique** est une statistique de l'échantillon à valeurs dans l'espaces des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$  définie par :

$$\hat{P}(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N \delta_{X_i}$$

où  $\delta_{X_i}$  est la mesure de Dirac en  $X_i : \forall A \in \mathcal{A}$ ,

$$\delta_{X_i}(A) = \begin{cases} 1 & \text{si } X_i \in A \\ 0 & \text{sinon} \end{cases}$$

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations,

$\hat{P}(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$  sera la mesure empirique associée à l'échantillon d'observations.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable. Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ . Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire **i.i.d.** de loi  $P_X$ . La **mesure empirique** est une statistique de l'échantillon à valeurs dans l'espaces des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$  définie par :

$$\hat{P}(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N \delta_{X_i}$$

où  $\delta_{X_i}$  est la mesure de Dirac en  $X_i : \forall A \in \mathcal{A}$ ,

$$\delta_{X_i}(A) = \begin{cases} 1 & \text{si } X_i \in A \\ 0 & \text{sinon} \end{cases}$$

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations,

$\hat{P}(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$  sera la mesure empirique associée à l'échantillon d'observations.

### Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

## I.2 - La Méthode Empirique

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire dans  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$ , soit  $(\mathcal{Z}, \mathcal{C})$  un espace mesurable.  
 Soit  $T$  une application mesurable de  $(\mathcal{X}^N, \mathcal{A}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$ .  
 Alors  $T_N = T \circ (X_1, \dots, X_N) = T(X_1, \dots, X_N)$  est une variable aléatoire de  $(\Omega^N, \mathcal{F}^{\otimes N})$  dans  $(\mathcal{Z}, \mathcal{C})$  appelée **statistique de l'échantillon**.

### Exemples

- La moyenne empirique :

$$T(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N X_i = \bar{X}$$

- Le maximum :

$$T(X_1, \dots, X_N) = \max(X_1, \dots, X_N)$$

### Définition

Soit  $(X_1, \dots, X_N)$ , un échantillon aléatoire **i.i.d.** de loi  $P_X$ .  
 La **mesure empirique** est une statistique de l'échantillon à valeurs dans l'espaces des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$  définie par :

$$\hat{P}(X_1, \dots, X_N) = \frac{1}{N} \sum_{i=1}^N \delta_{X_i}$$

où  $\delta_{X_i}$  est la mesure de Dirac en  $X_i : \forall A \in \mathcal{A}$ ,

$$\delta_{X_i}(A) = \begin{cases} 1 & \text{si } X_i \in A \\ 0 & \text{sinon} \end{cases}$$

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations,  
 $\hat{P}(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N \delta_{x_i}$  sera la mesure empirique associée à l'échantillon d'observations.

### Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

### Exemples

- La moyenne empirique**

Soit  $X$ , v.a. dans  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , intégrable, de loi  $P$ .

$$\begin{aligned} G : P &\mapsto \mathbb{E}(X) = \int_{\mathbb{R}} x P(dx) \\ &= \int_{\mathbb{R}} x p(x) dx \quad (\text{si } P \text{ admet une densité } p) \end{aligned}$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} x \hat{P}(x_1, \dots, x_N)(dx) \\ &= \int_{\mathbb{R}} x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

## Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

## Exemples

- La **moyenne empirique**

Soit  $X$ , v.a. dans  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , intégrable, de loi  $P$ .

$$\begin{aligned} G : P &\mapsto \mathbb{E}(X) = \int_{\mathbb{R}} x P(dx) \\ &= \int_{\mathbb{R}} x p(x) dx \text{ (si } P \text{ admet une densité } p) \end{aligned}$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} x \hat{P}(x_1, \dots, x_N)(dx) \\ &= \int_{\mathbb{R}} x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

## Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

## Exemples

- La **moyenne empirique**

Soit  $X$ , v.a. dans  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , intégrable, de loi  $P$ .

$$\begin{aligned} G : P &\mapsto \mathbb{E}(X) = \int_{\mathbb{R}} x P(dx) \\ &= \int_{\mathbb{R}} x p(x) dx \text{ (si } P \text{ admet une densité } p) \end{aligned}$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} x \hat{P}(x_1, \dots, x_N)(dx) \\ &= \int_{\mathbb{R}} x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

## Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

## Exemples

- La **moyenne empirique**

Soit  $X$ , v.a. dans  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , intégrable, de loi  $P$ .

$$\begin{aligned} G : P &\mapsto \mathbb{E}(X) = \int_{\mathbb{R}} x P(dx) \\ &= \int_{\mathbb{R}} x p(x) dx \text{ (si } P \text{ admet une densité } p) \end{aligned}$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} x \hat{P}(x_1, \dots, x_N)(dx) \\ &= \int_{\mathbb{R}} x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques**

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$\begin{aligned} G(P) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc} \\ G(\hat{P}(x_1, \dots, x_N)) &= \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2 \end{aligned}$$

On note  $S^2$  la statistique associée.

## Méthode empirique

$X \sim P_X$ ,  $P_X$  inconnue.

La **méthode empirique** vise à approcher les caractéristiques de  $P_X$  à partir d'un échantillon d'observations  $(x_1, \dots, x_N)$  pour des v.a. i.i.d. de loi  $P_X$ .

Si la caractéristique s'exprime par une fonctionnelle  $G$  sur l'ensemble des mesures de probabilité sur  $(\mathcal{X}, \mathcal{A})$ , alors : la caractéristique empirique approche la vraie caractéristique

$$G(\hat{P}(x_1, \dots, x_N)) \approx G(P_X)$$

où la caractéristique empirique est la fonctionnelle  $G$  appliquée à la mesure empirique.

## Exemples

- La **moyenne empirique**

Soit  $X$ , v.a. dans  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ , intégrable, de loi  $P$ .

$$\begin{aligned} G : P &\mapsto \mathbb{E}(X) = \int_{\mathbb{R}} x P(dx) \\ &= \int_{\mathbb{R}} x p(x) dx \text{ (si } P \text{ admet une densité } p) \end{aligned}$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} x \hat{P}(x_1, \dots, x_N)(dx) \\ &= \int_{\mathbb{R}} x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{\mathbb{R}} x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N x_i \end{aligned}$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques**

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$\begin{aligned} G(P) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc} \\ G(\hat{P}(x_1, \dots, x_N)) &= \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2 \end{aligned}$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique**

$[G(P)](x) = \int_{-\infty}^x P(dx)$ , soit :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$





- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$G(P) = \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc}$$

$$G(\hat{P}(x_1, \dots, x_N)) = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2$$


On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$[G(P)](x) = \int_{-\infty}^x P(dx)$ , soit :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

Ex. fonctions de répartitions empiriques pour  $\mathcal{N}(10; 5)$



- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$\begin{aligned} G(P) &= \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc} \\ G(\hat{P}(x_1, \dots, x_N)) &= \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2 \end{aligned}$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$[G(P)](x) = \int_{-\infty}^x P(dx)$ , soit :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i} (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$G(P) = \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc}$$

$$G(\hat{P}(x_1, \dots, x_N)) = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$$[G(P)](x) = \int_{-\infty}^x P(dx), \text{ soit :}$$

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i} (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

### I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$G(P) = \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc}$$

$$G(\hat{P}(x_1, \dots, x_N)) = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$[G(P)](x) = \int_{-\infty}^x P(dx)$ , soit :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_{\Theta} = \{P_{\theta}, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_{\Theta} = \{p_{\theta}, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_{\Theta} = \{P_{\lambda}, \lambda \in \mathbb{R}_+\}, P_{\lambda}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$G(P) = \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc}$$

$$G(\hat{P}(x_1, \dots, x_N)) = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$$[G(P)](x) = \int_{-\infty}^x P(dx), \text{ soit :}$$

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i}(dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

### I.3 - Modèles Statistiques Paramétriques

#### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_{\Theta} = \{P_{\theta}, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_{\Theta} = \{p_{\theta}, \theta \in \Theta\}$$

#### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_{\Theta} = \{P_{\lambda}, \lambda \in \mathbb{R}_+\}, P_{\lambda}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_{\Theta} = \{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\},$$

$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x-\mu}{\sigma} \right)^2}.$$

- $\mathbb{E}(h(X))$

Idem : si  $h : (\mathcal{X}, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $P$ -intégrable.

$$G : P \mapsto \mathbb{E}(h(X)) = \int_{\mathbb{R}} h(x) P(dx)$$

En appliquant  $G$  à la mesure empirique :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N)) &= \int_{\mathbb{R}} h(x) \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N h(x_i) \end{aligned}$$

- Moments et variance empiriques

En prenant  $h(X) = X^k$ , nous obtenons les **moments empiriques**

$$\hat{m}_k(x_1, \dots, x_N) = \frac{1}{N} \sum_{i=1}^N x_i^k$$

On en déduit la **variance empirique** :

$$G(P) = \mathbb{E}(X^2) - \mathbb{E}(X)^2, \text{ et donc}$$

$$G(\hat{P}(x_1, \dots, x_N)) = \frac{1}{N} \sum_{i=1}^N x_i^2 - \left( \frac{1}{N} \sum_{i=1}^N x_i \right)^2$$

On note  $S^2$  la statistique associée.

- Fonction de répartition empirique

$[G(P)](x) = \int_{-\infty}^x P(dx)$ , soit :

$$\begin{aligned} G(\hat{P}(x_1, \dots, x_N))(x) &= \int_{-\infty}^x \left( \frac{1}{N} \sum_{i=1}^N \delta_{x_i} \right) (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \int_{-\infty}^x \delta_{x_i} (dx) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{I}_{]-\infty; x]}(x_i) \end{aligned}$$

### I.3 - Modèles Statistiques Paramétriques

#### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_{\Theta} = \{P_{\theta}, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_{\Theta} = \{p_{\theta}, \theta \in \Theta\}$$

#### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_{\Theta} = \{P_{\lambda}, \lambda \in \mathbb{R}_+\}, P_{\lambda}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\begin{aligned} \mathcal{M}_{\Theta} &= \left\{ p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^* \right\}, \\ P_{(\mu, \sigma^2)}(x) &= \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{x-\mu}{\sigma} \right)^2}. \end{aligned}$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_{\Theta} = \{p_{\theta}(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left( \frac{y - \beta^t x}{\sigma} \right)^2}$$

### I.3 - Modèles Statistiques Paramétriques

#### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

#### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \left\{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\right\},$$

$$p_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \left\{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\right\},$$

$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .



## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^P$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\},$$
$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^P$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\},$$
$$p_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un **estimateur** de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^P$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \{p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\},$$
$$p_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^P$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un **estimateur** de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

### II.1 - Méthodes d'estimation ponctuelle

#### II.1.a - Méthode des moments

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \left\{P_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\right\},$$
$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un **estimateur** de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \left\{P_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^*\right\},$$
$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un **estimateur** de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

### II.1 - Méthodes d'estimation ponctuelle

#### II.1.a - Méthode des moments

$$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$$\hat{g} = G\left(\hat{P}(x_1, \dots, x_N)\right) \Rightarrow p \text{ premiers moments empiriques}$$

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$

(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

## I.3 - Modèles Statistiques Paramétriques

### Définition

Un **modèle statistique** sur  $(\mathcal{X}, \mathcal{A})$  est une famille de lois de probabilités sur  $(\mathcal{X}, \mathcal{A})$ .

Si cette famille peut être paramétrée par  $\theta \in \Theta \subset \mathbb{R}^p$ , on parle de **modèle statistique paramétrique**. On note :

$$\mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$$

Si la famille est dominée par une mesure  $\sigma$ -finie, alors les lois admettent des densités. On note :

$$\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta\}$$

### Exemples

- Famille des lois de Poisson

$$\mathcal{M}_\Theta = \{P_\lambda, \lambda \in \mathbb{R}_+\}, P_\lambda(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

- Famille des lois Gaussiennes

$$\mathcal{M}_\Theta = \left\{ p_{(\mu, \sigma^2)}, \mu \in \mathbb{R}, \sigma^2 \in \mathbb{R}_+^* \right\},$$
$$P_{(\mu, \sigma^2)}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}.$$

- Modèles de régression

$X \in (\mathcal{X}, \mathcal{A})$  : variables explicatives,  $Y \in (\mathcal{Y}, \mathcal{B})$  : variables à expliquer.

Un modèle de régression est une **famille de lois de densités conditionnelles**

$$\mathcal{M}_\Theta = \{p_\theta(y|x), \theta \in \Theta\}$$

Par exemple, **régression linéaire** :  $Y$  v.a. dans  $\mathbb{R}$ ,  $X$  v.a. dans  $\mathbb{R}^p$ ,  $\xi \sim \mathcal{N}(0; \sigma^2)$ .

$$Y = \beta^t X + \xi,$$

$$p_{(\beta, \sigma^2)}(y|x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta^t x}{\sigma}\right)^2}$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'**inférence sur  $P^*$**  est alors ramené au problème d'**estimation du paramètre  $\theta^*$** .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un **estimateur** de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

### II.1 - Méthodes d'estimation ponctuelle

#### II.1.a - Méthode des moments

$$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$$\hat{g} = G\left(\hat{P}(x_1, \dots, x_N)\right) \Rightarrow p \text{ premiers moments empiriques}$$

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$

(ou tel que  $\hat{\theta} = \arg \min \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$

(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée vraisemblance du paramètre  $\theta$  en  $x$ , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$



## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}, P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}, p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

#### Définition

Pour une observation ou un échantillon d'observations  $x$ , si  $\hat{\theta}(x)$  maximise la vraisemblance  $\mathcal{L}(\theta; x)$  sur  $\Theta$

$\hat{\theta}(x)$  sera appelée **estimation du maximum de vraisemblance** et l'estimateur associé  $\hat{\theta}(X)$ , estimateur du maximum de vraisemblance (EMV).

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

#### Définition

Pour une observation ou un échantillon d'observations  $x$ , si  $\hat{\theta}(x)$  maximise la vraisemblance  $\mathcal{L}(\theta; x)$  sur  $\Theta$

$\hat{\theta}(x)$  sera appelée **estimation du maximum de vraisemblance** et l'estimateur associé  $\hat{\theta}(X)$ , estimateur du maximum de vraisemblance (EMV).

On note :

$$\hat{\theta}(x) = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta; x).$$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

#### Définition

Pour une observation ou un échantillon d'observations  $x$ , si  $\hat{\theta}(x)$  maximise la vraisemblance  $\mathcal{L}(\theta; x)$  sur  $\Theta$

$\hat{\theta}(x)$  sera appelée **estimation du maximum de vraisemblance** et l'estimateur associé  $\hat{\theta}(X)$ , estimateur du maximum de vraisemblance (EMV).

On note :

$$\hat{\theta}(x) = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta; x).$$

#### Remarques

- Souvent on maximise plutôt  $\ell(\theta; x) = \ln(\mathcal{L}(\theta; x))$

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

#### Définition

Pour une observation ou un échantillon d'observations  $x$ , si  $\hat{\theta}(x)$  maximise la vraisemblance  $\mathcal{L}(\theta; x)$  sur  $\Theta$   $\hat{\theta}(x)$  sera appelée **estimation du maximum de vraisemblance** et l'estimateur associé  $\hat{\theta}(X)$ , estimateur du maximum de vraisemblance (EMV).

On note :

$$\hat{\theta}(x) = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta; x).$$

#### Remarques

- Souvent on maximise plutôt  $\ell(\theta; x) = \ln(\mathcal{L}(\theta; x))$
- Existence et unicité pas forcément assurées

## II - Estimation Paramétrique

Soit  $X \sim P^*$ ,  $P^*$  inconnue. On suppose que  $P^*$  appartient à un modèle paramétrique  $P^* \in \mathcal{M}_\Theta \{P_\theta, \theta \in \Theta\}$ , et donc  $\exists \theta^* \in \Theta$  tel que  $P^* = P_{\theta^*}$ .

$\Rightarrow$  Le problème d'inférence sur  $P^*$  est alors ramené au problème d'estimation du paramètre  $\theta^*$ .

### Définition

Soit  $(X_1, \dots, X_N)$  un échantillon i.i.d. pour une loi  $P_{\theta^*}$ . Un estimateur de  $\theta^*$  est une statistique  $T(X_1, \dots, X_N)$  à valeurs dans  $\Theta$  visant à estimer  $\theta^*$ .

## II.1 - Méthodes d'estimation ponctuelle

### II.1.a - Méthode des moments

$X \sim P_{\theta^*}$ ,  $P_{\theta^*} \in \mathcal{M}_\Theta = \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

On considère la fonctionnelle  $G$  sur l'espaces des mesures de probabilités sur  $(\mathcal{X}, \mathcal{A})$ ,  $G : P \mapsto (\mathbb{E}_P(X), \dots, \mathbb{E}_P(X^p))$ .

Alors, pour tout  $\theta \in \Theta$ ,  $G(P_\theta) := g(\theta)$ .

Soit  $(x_1, \dots, x_N)$  un échantillon d'observations i.i.d. pour  $X$ , on calcule  $G$  en la mesure empirique

$\hat{g} = G(\hat{P}(x_1, \dots, x_N)) \Rightarrow p$  premiers moments empiriques

et on cherche  $\hat{\theta}$  tel que  $g(\hat{\theta}) = \hat{g}$   
(ou tel que  $\hat{\theta} = \arg \min_{\theta} \|g(\theta) - \hat{g}\|^2$ )

$\Rightarrow \hat{\theta}$  est un estimateur de  $\theta^*$ .

### II.1.b - Maximum de vraisemblance

#### Définition

Soit  $\mathcal{M}_\Theta$ , modèle paramétrique dominé, représenté par une famille de densités :  $\mathcal{M}_\Theta = \{p_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$

Soit  $X \sim p_{\theta^*}$ ,  $p_{\theta^*} \in \mathcal{M}_\Theta$ . Soit une observation  $x \in \mathcal{X}$  pour la variable aléatoire  $X$ .

La fonction :  $\theta \in \Theta, \theta \mapsto p_\theta(x)$  est appelée **vraisemblance du paramètre  $\theta$  en  $x$** , on la notera  $\mathcal{L}(\theta; x)$ .

Pour un échantillon d'observations  $(x_1, x_2, \dots, x_N)$  pour des variables aléatoires i.i.d, la vraisemblance s'écrit :

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_\theta(x_i),$$

ou

$$\mathcal{L}(\theta; x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i | \theta).$$

La vraisemblance du paramètre  $\theta$  correspond ainsi à sa **plausibilité** pour un certain jeu de données observées.

#### Définition

Pour une observation ou un échantillon d'observations  $x$ , si  $\hat{\theta}(x)$  maximise la vraisemblance  $\mathcal{L}(\theta; x)$  sur  $\Theta$

$\hat{\theta}(x)$  sera appelée **estimation du maximum de vraisemblance** et l'estimateur associé  $\hat{\theta}(X)$ , estimateur du maximum de vraisemblance (EMV).

On note :

$$\hat{\theta}(x) = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta; x).$$

#### Remarques

- Souvent on maximise plutôt  $\ell(\theta; x) = \ln(\mathcal{L}(\theta; x))$
- Existence et unicité pas forcément assurées
- Si  $\hat{\theta}$  est un point intérieur à  $\Theta$ , CN d'optimalité :  $\nabla \mathcal{L}(\theta) = 0$  (CNS si  $\mathcal{L}(\theta)$  concave et  $\Theta$  convexe).

