

TD 2 - Intervalles de Confiance

Exercice 2.1. On effectue un sondage sur un échantillon de 400 électeurs. On relève 212 intentions de vote en faveur d'un candidat A , 188 en faveur de B .

1. Donner au niveau de 95%, un intervalle de confiance asymptotique des intentions de vote en faveur de A dans la population entière.
2. Quelle taille minimale de l'échantillon faudrait-il prendre pour que, au même niveau de 95% et pour la même proportion de votants en faveur de A , l'intervalle ne contienne pas la valeur 0.5 ?

Solution:

1. Soit \hat{p}_n , la variable aléatoire correspondant à la proportion d'individus votant pour A dans un échantillon de taille n , et soit p la proportion théorique dans la population.

\hat{p}_n est la moyenne empirique de n variables i.i.d de Bernoulli $B(p)$ (nous rappelons que $B(p)$ a pour moyenne p et pour variance $p(1-p)$). Donc, le théorème central limite donne:

$$\sqrt{n}(\hat{p}_n - p) \xrightarrow{\mathcal{L}} \mathcal{N}(0, p(1-p))$$

La loi limite dépend du paramètre inconnu, mais on peut réécrire:

$$\sqrt{n} \frac{(\hat{p}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

$\sqrt{n} \frac{(\hat{p}_n - p)}{\sqrt{p(1-p)}}$ est donc une variable aléatoire asymptotiquement pivotale. Malgré tout, la construction de l'IC nous conduit à résoudre des inégalités. C'est encore possible explicitement ici, mais il y a une méthode plus simple, en utilisant le théorème de Slutsky. On a:

$$\sqrt{n} \frac{(\hat{p}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

et comme $\hat{p}_n \xrightarrow{\mathbb{P}} p$ par la loi des grands nombres, en utilisant le théorème de continuité

$$\frac{\sqrt{p(1-p)}}{\sqrt{\hat{p}_n(1-\hat{p}_n)}} \xrightarrow{\mathbb{P}} 1.$$

On peut donc utiliser le théorème de Slutsky pour conclure que:

$$\sqrt{n} \frac{\hat{p}_n - p}{\sqrt{\hat{p}_n(1-\hat{p}_n)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

Cette variable aléatoire est donc également asymptotiquement pivotale, mais plus simple que la précédente. On en déduit un intervalle de confiance de niveau asymptotique $1 - \alpha$:

$$I = [\hat{p}_n - q_{1-\alpha/2}^{\mathcal{N}} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}, \hat{p}_n + q_{1-\alpha/2}^{\mathcal{N}} \sqrt{\frac{\hat{p}_n(1-\hat{p}_n)}{n}}]$$

Numériquement, on trouve $\hat{p}_{400} = 212/400 = 0.53$, $q_{0.975}^N = 1.96$ et $\sqrt{\frac{\hat{p}_{400}(1-\hat{p}_{400})}{400}} \simeq 2.510^{-2}$. D'où $I = [0.48, 0.58]$.

N.B.: On a la loi exacte pour le nombre d'invidus N_A qui votent pour A dans l'échantillon, N_A suit une loi binomiale de paramètres N, p : $N_A \sim B(N, p)$. Malheureusement, il n'est pas possible de déterminer à partir de cette loi exacte une fonction pivotale. C'est pour cette raison que nous utilisons une fonction pivotale asymptotique.

2. On résout $0.53 - 1.96 \sqrt{\frac{0.53(1-0.53)}{n}} > 0.5$ et on obtient $n > (1.96/0.03)^2 \times 0.53 \times 0.47 \simeq 1063$. D'où $n = 1064$ convient.

- Exercice 2.2.** 1. Soit X_1, \dots, X_N un échantillon i.i.d. pour la loi de Poisson $\mathcal{P}(\theta)$. Donner l'estimateur de θ par la méthode des moments et montrer qu'il est asymptotiquement normal. Trouver une transformation qui stabilise la variance asymptotique associée à l'estimateur, c'est à dire une fonction h de classe C^1 sur l'ensemble des paramètres telle que la variance asymptotique associée à l'estimateur de $h(\theta)$ ne dépende pas de θ .
2. On dispose d'un échantillon i.i.d. de taille $N = 400$ d'une loi de Poisson $\mathcal{P}(\theta)$ de paramètre θ inconnu. Proposer deux intervalles de confiance au niveau asymptotique 0.99 pour θ , fondés sur l'estimateur du maximum de vraisemblance. Le premier fera appel au résultat de la question 1., le second au théorème de Slutsky.

Solution: 1. $\mathbb{E}(X_1) = \theta$. L'estimateur de la méthode des moments est donc $\hat{\theta} = \bar{X}$. De plus, on a: $\mathbb{V}(X_1) = \theta$. Le théorème central limite donne: $\sqrt{N}(\hat{\theta} - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \theta)$. L'estimateur est asymptotiquement normal de variance associée θ . Comme θ est inconnu, on cherche à se ramener à un estimateur dont la variance asymptotique associée ne dépend pas de θ .

Soit h de classe C^1 telle que $h'(\theta) \neq 0$. Par la méthode delta, nous avons:

$$\sqrt{N}(h(\hat{\theta}) - h(\theta)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \theta(h'(\theta))^2)$$

En prenant $h(\theta) = \sqrt{\theta}$, nous avons alors:

$$\sqrt{N}(\sqrt{\hat{\theta}} - \sqrt{\theta}) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \frac{1}{4})$$

2. On trouve l'intervalle de confiance asymptotique de niveau $0.99 = 1 - \alpha$ (donc $\alpha = 0.01$):

$$I_\infty = [(\max(0, \sqrt{\bar{x}} - \frac{q_{1-\alpha/2}^N}{2\sqrt{N}}))^2, (\sqrt{\bar{x}} + \frac{q_{1-\alpha/2}^N}{2\sqrt{N}})^2].$$

En utilisant la table de la loi normale, on trouve $q_{1-\alpha/2}^N = 2.58$. L'application numérique donne:

$$I_\infty = [(\max(0, \sqrt{\bar{x}} - 0,065))^2, (\sqrt{\bar{x}} + 0,065)^2].$$

Une autre solution possible consiste à utiliser le fait que : $\frac{\sqrt{N}(\bar{x} - \theta)}{\sqrt{\bar{x}}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$ d'après le théorème de Slutsky. Il fournit un intervalle de confiance légèrement différent mais asymptotiquement équivalent au précédent :

$$I'_\infty = \left[\max \left(0, \bar{x} - \frac{q_{1-\alpha/2}^N}{\sqrt{N}} \sqrt{\bar{x}} \right), \bar{x} + \frac{q_{1-\alpha/2}^N}{\sqrt{N}} \sqrt{\bar{x}} \right]$$

On reconnaît le développement des carrés dans I_∞ sans le terme en $1/N$ asymptotiquement négligeable devant les deux autres termes. Numériquement

$$I'_\infty = \left[\max \left(0, \bar{x} - 0.129\sqrt{\bar{x}} \right), \bar{x} + 0.129\sqrt{\bar{x}} \right].$$

Exercice 2.3. On considère un échantillon X_1, \dots, X_n de variables aléatoires i.i.d. selon une loi géométrique décrite par sa fonction de masse

$$\forall k \in \mathbb{N}^*, p_\theta(k) = \mathbb{P}_\theta(X = k) = \theta(1 - \theta)^{k-1}$$

où θ est le paramètre inconnu de la loi. On admettra les relations

$$\mathbb{E}_\theta(X) = \frac{1}{\theta} \text{ et } \mathbb{V}_\theta(X) = \frac{1 - \theta}{\theta^2}$$

1. Trouver l'estimateur du maximum de vraisemblance de θ , que l'on notera $\hat{\theta}_n$.
2. Appliquer, en le justifiant, le théorème central limite à la moyenne empirique \bar{X}_n .
3. En déduire, en utilisant le théorème de Slutsky, une fonction asymptotiquement pivotale avec une dépendance en θ aussi simple que possible.
4. Construire un intervalle de confiance asymptotique pour θ de niveau $1 - \alpha$.
5. Application numérique: On observe un échantillon de taille $n = 25$ et on obtient la distribution empirique suivante :

Valeurs de k	1	2	3	4	5	6	7
Nombre d'occurrences n_k	11	4	3	3	2	1	1

Calculer l'intervalle de confiance sur θ pour ce jeu de données au niveau 0,95.

Solution:

1. Soit l'échantillon d'observations $x = (x_1, \dots, x_n)$. Nous avons la vraisemblance:

$$\mathcal{L}(\theta; x) = \prod_{i=1}^n p_\theta(x_i) = \theta^n (1 - \theta)^{n\bar{x} - n}$$

La log-vraisemblance :

$$\ell(\theta) = n \ln \theta + n(\bar{x} - 1) \ln(1 - \theta) .$$

Si $\bar{x} = 1$, pas de maximum, sinon:

$$\ell'(\theta) = n/\theta - n(\bar{x} - 1)/(1 - \theta)$$

et l'EMV est défini par la CN, $\ell'(\theta) = 0$ soit $\hat{\theta} = 1/\bar{x}$

Justification : $\forall \theta, \ell''(\theta) < 0$ ℓ est concave, donc $\hat{\theta}$ est bien un max.

2. On a, d'après le TCL:

$$\sqrt{n}(\bar{X}_n - 1/\theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, (1 - \theta)/\theta^2)$$

car \bar{X}_n moyenne empirique de v.a. i.i.d. telles que $\mathbb{E}(X_1^2) < +\infty$.

3. Par la loi des grands nombres, on a $\bar{X}_n \xrightarrow{\mathbb{P}} \frac{1}{\theta}$.

donc par le théorème de continuité $\sqrt{1 - 1/\bar{X}_n} \xrightarrow{\mathbb{P}} \sqrt{1 - \theta}$

et enfin avec le théorème de Slutsky

$$\sqrt{n} \frac{(\theta \bar{X}_n - 1)}{\sqrt{1 - (1/\bar{X}_n)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

4. On pose Φ la fonction de répartition de la loi $\mathcal{N}(0, 1)$. En utilisant le TCL, on a

$$\lim_{n \rightarrow \infty} \left[\mathbb{P}(\Phi^{-1}(\alpha/2) \leq \sqrt{n} \frac{(\theta \bar{X}_n - 1)}{\sqrt{1 - (1/\bar{X}_n)}} \leq \Phi^{-1}(1 - \alpha/2)) \right] = 1 - \alpha$$

et on a:

$$I_{\infty}(n, \alpha) = \left[\frac{1}{\bar{x}} \left(\left(1 + \frac{\sqrt{1 - (1/\bar{x})}}{\sqrt{n}} \Phi^{-1}(\alpha/2) \right), \frac{1}{\bar{x}} \left(\left(1 + \frac{\sqrt{1 - (1/\bar{x})}}{\sqrt{n}} \Phi^{-1}(1 - (\alpha/2)) \right) \right) \right]$$

A noter que: $\Phi^{-1}(1 - (\alpha/2)) = q_{1-\alpha/2}^{\mathcal{N}}$ et $\Phi^{-1}(\alpha/2) = -q_{1-\alpha/2}^{\mathcal{N}}$.

$$5. \text{ A.N. } \bar{x} = \frac{1}{n} \sum_{k=1}^7 kn_k = 2.52.$$


$$\Phi^{-1}(0.975) = 1.96, I_{\infty}(25, 0.05) = [0.27; 0.51].$$

Malgré tout, avec $N = 25$, l'approximation asymptotique reste discutable.

Annexe: Table

Loi Normale centrée réduite

Probabilité de trouver une valeur inférieure à x.



$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

X	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998